

Questão 1

$$y_t = \gamma x_t + u_t \quad \mu_t = \phi \mu_{t-1} + a_t = \theta a_{t-1} \quad a_t \sim N(0, \sigma^2)$$

1- Temos que:

$$y_{t-1} = \gamma x_{t-1} + u_{t-1} \Leftrightarrow \mu_{t-1} = y_{t-1} - \gamma x_{t-1}$$

Substituindo μ_t e μ_{t-1} :

$$y_t = \gamma x_t + \phi \mu_{t-1} + a_t - \theta a_{t-1} = \gamma x_t - \phi \gamma x_{t-1} + \phi y_{t-1} + a_t - \theta a_{t-1} \Rightarrow$$

$$\Rightarrow (y_t - \gamma x_t) - \phi B(y_{t-1} - \gamma x_{t-1}) = (a_t) - \theta B(a_{t-1})$$

$$\phi(B) = 1 - \phi B \quad \theta(B) = 1 - \theta B$$

$$\phi(B)(y_t - \gamma x_t) = \theta(B)a_t$$

2- Temos que:

$$F_t = (x_0, \dots, x_t, y_0, \dots, y_{t-1}, a_0 = 0)$$

$$E(y_t | F_t) = \gamma x_t - \phi \gamma x_{t-1} + \phi y_{t-1} + E(a_t) - \theta a_{t-1}$$

$$\text{Var}(y_t | F_t) = \text{Var}(a_t) = \sigma^2$$

$$a_{t-1} = y_{t-1} - \gamma x_{t-1} - \phi(y_{t-2} - \gamma x_{t-2}) + \theta a_{t-2}$$

Logo, a distribuição conjunta de y_1, \dots, y_T com y_t gaussiano:

$$P(y_1, \dots, y_T | y_0, a_0 = 0) = \frac{1}{(2\pi\sigma^2)^T/2} \exp\left[-\left(\frac{1}{2\sigma^2} \sum_{t=1}^T y_t - E(y_t | F_t)\right)^2\right]$$

Seja $\eta = (\phi, \theta, \sigma)$, a verossimilhança condicionada a $x_0, \dots, x_t, y_0, a_0 = 0$:

$$L(\eta) = \frac{1}{(2\pi\sigma^2)^T/2} \exp\left[-\left(\frac{1}{2\sigma^2} \sum_{t=1}^T y_t - \gamma x_t - \phi \gamma x_{t-1} + \phi y_{t-1} - \theta a_{t-1}\right)^2\right]$$

3- $E(X_t | a_{t-j}) = 0, \quad \forall t, j > 0$

O estimador de OLS será o seguinte:

$$\hat{Y}_{OLS} = \arg \min_{\gamma} \sum_{t=1}^n (y_t - \gamma x_t)^2 \Rightarrow \hat{Y}_{OLS} = \left(\sum_{t=1}^n x_t^2 \right)^{-1} \sum_{t=1}^n x_t y_t$$

Calculando a média do estimador:

$$\begin{aligned} E(\hat{Y}_{OLS} | \{X_i = x_i\}_{i=1}^n) &= E\left[\frac{\sum_{t=1}^n x_t y_t}{\sum_{t=1}^n x_t^2} \mid \{X_i = x_i\}_{i=1}^n\right] = E\left[\frac{\sum_{t=1}^n x_t (\gamma x_t + \mu_t)}{\sum_{t=1}^n x_t^2} \mid \{X_i = x_i\}_{i=1}^n\right] \\ &= E\left[\frac{\gamma \sum_{t=1}^n x_t^2 + \sum_{t=1}^n x_t u_t}{\sum_{t=1}^n x_t^2} \mid \{X_i = x_i\}_{i=1}^n\right] = \gamma + \frac{\sum_{t=1}^n x_t E[u_t | \{X_i = x_i\}_{i=1}^n]}{\sum_{t=1}^n x_t^2} \end{aligned}$$

Vamos calcular a forma de choques aleatórios de U_t :

$$\mu_t = \phi \mu_{t-1} + a_t = \phi(\phi \mu_{t-2} + a_{t-1} - \theta a_{t-2}) + a_t - \theta a_{t-1}$$

$$= \phi^2 \mu_{t-2} + a_t + a_{t-1}(\phi - \theta) - \phi \theta a_{t-2} = \phi^2(\phi \mu_{t-3} + a_{t-2} - \theta a_{t-3} + a_t + a_{t-1}(\phi - \theta)) - \phi \theta a_{t-2}$$

$$= \phi^3 \mu_{t-3} + a_t + a_{t-1}(\phi - \theta) + a_{t-2}(\phi^2 - \phi \theta) - \phi^2 a_{t-2}$$

Podemos notar que:

$$\mu_t = a_t + \sum_{j=1}^J a_{t-j}(\phi^j - \phi^{j-1}\theta) = \Psi(B)a_t \quad \text{com } \Psi(B) = 1 + (\phi - \theta)B + (\phi^2 - \phi \theta)B^2 + \dots$$

Logo:

$$E[a_{t-j} x_t] = 0$$

$$E[\hat{Y}_{OLS} | \{X_i = x_i\}_{i=1}^n] = \gamma + \frac{\sum_{t=1}^n x_t E[\Psi(B)a_t | X_t]}{\sum_{t=1}^n x_t^2}$$

→ $\gamma + \gamma + \gamma + \dots + \gamma = J\gamma$

$$E[\gamma_{ols} | \{X_i = X_t\}_{i=1}^n] = \gamma + \frac{\sum_{t=1}^n X_t \psi(B) \alpha_t}{\sum_{t=1}^n X_t^2}$$

$$E[\gamma_{ols}] = E(E[\gamma_{ols} | \{X_i = X_t\}_{i=1}^n]) = E(\gamma) = \gamma$$

Logo, γ_{ols} é não enviesado. Calculando a variância:

$$\begin{aligned} \text{Var}(\gamma_{ols} | \{X_i = X_t\}_{i=1}^n) &= \text{Var}\left(\gamma + \frac{\sum_{t=1}^n X_t \alpha_t}{\sum_{t=1}^n X_t^2} \mid \{X_i = X_t\}_{i=1}^n\right) = \\ &= \text{Var}\left(\frac{\sum_{t=1}^n X_t \psi(B) \alpha_t}{\sum_{t=1}^n X_t^2} \mid \{X_i = X_t\}_{i=1}^n\right) = \frac{\psi^2(B)}{\left(\sum_{t=1}^n X_t^2\right)^2} \text{Var}\left(\sum_{t=1}^n X_t \alpha_t \mid \{X_i = X_t\}_{i=1}^n\right) \\ &= \frac{\psi^2(B)}{\left(\sum_{t=1}^n X_t^2\right)^2} \sum_{t=1}^n X_t^2 \text{Var} \alpha_t = \frac{\psi^2(B) \sigma^2}{\left(\sum_{t=1}^n X_t^2\right)} = \frac{\sum_{j=1}^n \phi^j (1 - \theta/\phi) \sigma^2}{\left(\sum_{t=1}^n X_t^2\right)} \\ &= \frac{1}{1-\phi} \cdot \frac{(\phi - \theta) \sigma^2}{\left(\sum_{t=1}^n X_t^2\right)} = \frac{(\phi - \theta) \sigma^2}{(1-\phi) \phi} \frac{1}{\left(\sum_{t=1}^n X_t^2\right)} \end{aligned}$$

4- $X_t = \beta X_{t-1} + \varepsilon_t \quad \varepsilon_t \sim N(0, \sigma^2) \quad E[\varepsilon_t \alpha_{t-j}] = 0 \quad \forall j.$

X_t é um AR(1). Podemos escrever $X_t = \varepsilon_t + \sum_{j=1}^{\infty} \beta^j \varepsilon_{t-j} = \omega(B) \varepsilon_t$

$$\gamma_{ols} = (\sum X_t^2)^{-1} (\sum X_t \varepsilon_t)$$

$$\begin{aligned} E(\gamma_{ols}) &= E(\gamma + (\sum X_t^2)^{-1} (\sum X_t \varepsilon_t)) = \gamma + E[(\sum (\omega(B) \varepsilon_t)^2)^{-1} (\sum \omega(B) \varepsilon_t \psi(B) \alpha_t)] \\ &= \gamma + E[(\sum \omega(B)^2 \varepsilon_t^2)^{-1} (\omega(B) \psi(B) \sum \varepsilon_t \alpha_t)] = \gamma + E[(\omega(B)^2 \sum \varepsilon_t^2)^{-1} (\omega(B) \psi(B) \sum \varepsilon_t \alpha_t)] \\ &= \gamma + E\left[\frac{\omega(B) \psi(B) \sum \varepsilon_t \alpha_t}{\omega(B)^2 \sum \varepsilon_t^2}\right] = \gamma + \frac{\psi(B)}{\omega(B)} E\left[\frac{\sum_{t=1}^n \varepsilon_t \alpha_t}{\sum_{t=1}^n \varepsilon_t^2}\right] = \gamma + \frac{\psi(B)}{\omega(B)} n \cdot E\left[E\left[\frac{\sum_{t=1}^n \varepsilon_t \alpha_t}{\sum_{t=1}^n \varepsilon_t^2} \mid \{\varepsilon_i = \varepsilon_i\}_{i=1}^n\right]\right] \\ &= \gamma + \frac{\psi(B)}{\omega(B)} E\left[\frac{\sum_{t=1}^n \varepsilon_t E[\alpha_t \mid \{\varepsilon_i = \varepsilon_i\}_{i=1}^n]}{\sum_{t=1}^n \varepsilon_t^2}\right] = \gamma \end{aligned}$$

O estimador é não enviesado.

5- Definimos a nossa previsão para $T+1$ como:

$$\hat{y}_T(1) = \hat{\gamma} \hat{X}_T(1); \quad \hat{\gamma} = \gamma_{ols}, \quad \hat{X}_T(1) = \beta X_T$$

Calculando o erro:

$$\begin{aligned} e_T(1) &= (y_{T+1}) - (\hat{y}_T) = (\gamma X_{T+1} + \varepsilon_{T+1}) - (\hat{\gamma} \hat{X}_T(1)) = \gamma (\beta X_T + \varepsilon_T) + \varepsilon_{T+1} - \hat{\gamma} \beta X_T \approx \\ &= (\gamma - \hat{\gamma}) \beta X_T + \gamma \varepsilon_T + \varepsilon_{T+1} \end{aligned}$$

Se formos calcular o valor esperado do erro:

$$\begin{aligned} E(e_T(1)) &= E[(\gamma - \hat{\gamma}) \beta X_T + \gamma \varepsilon_T + \varepsilon_{T+1}] = (\gamma - E(\hat{\gamma})) \beta E(X_T) + \gamma E(\varepsilon_T) + E(\varepsilon_{T+1}) = \\ &= (\gamma - \gamma) \beta E(X_T) = 0 \end{aligned}$$

Questão 2

Inicialmente devemos utilizar o método de Box-Jenkins para encontrar um modelo SARIMA para o período pré-intervenção. Com os dados até junho de 2008:

- Verificamos se é necessário uma transformação para estabilizar a variância (log ou Boxcox)
- Definimos o grau de diferenciação necessário, tanto com lag = 1 quanto com lag = 12, verificando com qual nível de diferenciação a série se torna estacionária (ADF test).
- Com a ACF e PACF identificamos os valores MA e AR para a parte não-sazonal e sazonal do modelo.
- Consideramos diferentes modelos e escolhemos aquele que otimiza certa medida, como o AIC (minimizar).

Depois de termos criado o modelo pré-intervenção podemos fazer um forecast para os meses logo após a intervenção para analisarmos como a série se comportaria sem a intervenção.

Para modelar a intervenção, precisamos escolher uma função de transferência que represente a intervenção, alguns padrões são:

- Acréscimo na média que se mantém após a intervenção.
- Acréscimo na média que ocorre no momento de intervenção mas depois retorna ao nível original.
- Acréscimo na média que cresce gradualmente até atingir determinado nível e se mantém.
- Acréscimo na média que ocorre no momento de intervenção e decresce gradualmente até retornar ao nível original.

Consideraremos uma ou mais funções de transferência e devemos estimar os parâmetros da intervenção e do modelo SARIMA utilizando agora todos os dados, pré e pós intervenção. Na linguagem R a função arimax é capaz de estimar os parâmetros do modelo.

Com o modelo de intervenção construído podemos prever a série para além do período observado.