ARMAmodel

```r
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':
##   method            from
##   as.zoo.data.frame zoo
```

```r
library(zoo)
```

```
##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##     as.Date, as.Date.numeric
```

```r
load("dados_arma_4.RData")

plot_acf_pacf <- function(series){
  par(mfrow = c(2, 1))
  acf(series, main = "ACF")
  pacf(series, main = "PACF")
}

plot_res <- function(res){
  plot(res, main = "Residuals of model",
       ylab = "Residual", type = "p")
  abline(0, 0)
}
```

Modelos ARMA

Com 9 séries temporais, iremos avaliar cada uma delas e identificar se ela é gerada por um modelo AR(p), um modelo MA(q) ou um modelo ARMA(p, q). Em todas as diferentes séreis iremos inicialmente visualizar a série, a função de autocorrelação e a função de autocorrelação parcial.

Série 1

```r
plot(X[[1]], main = "Series 1", ylab = "Z_t")
```

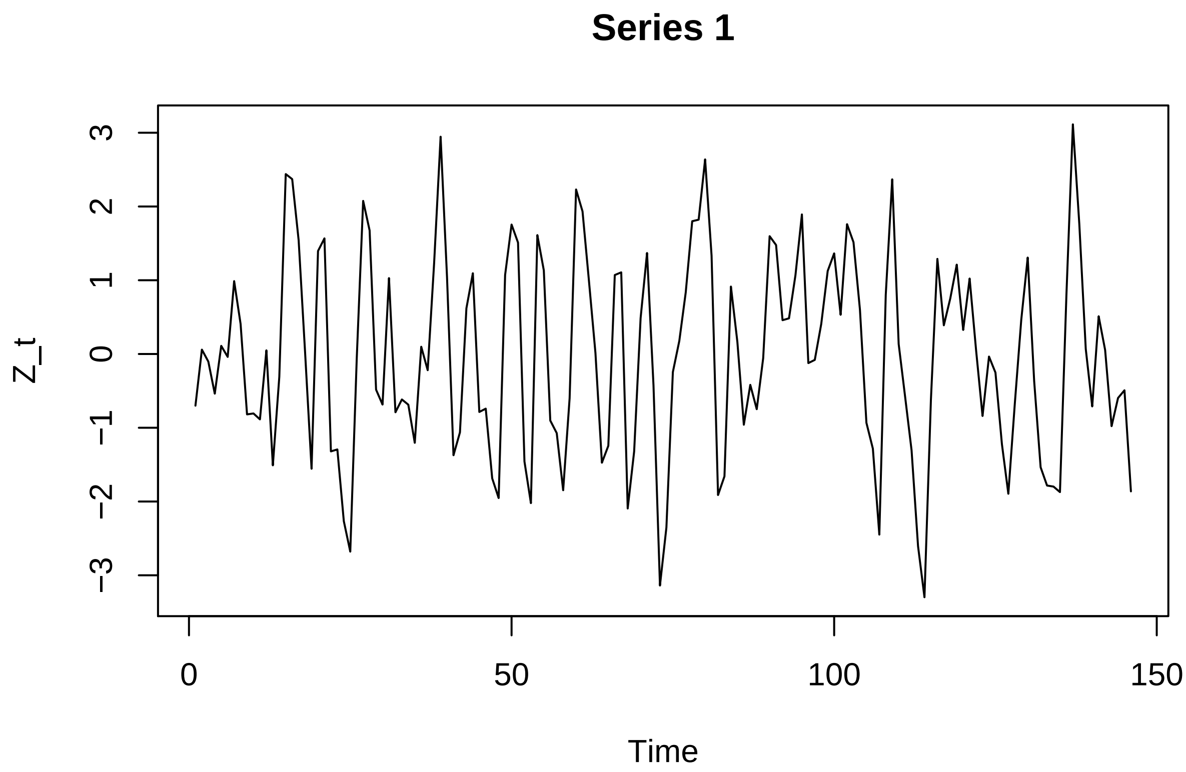


```
plot_acf_pacf(X[[1]])
```

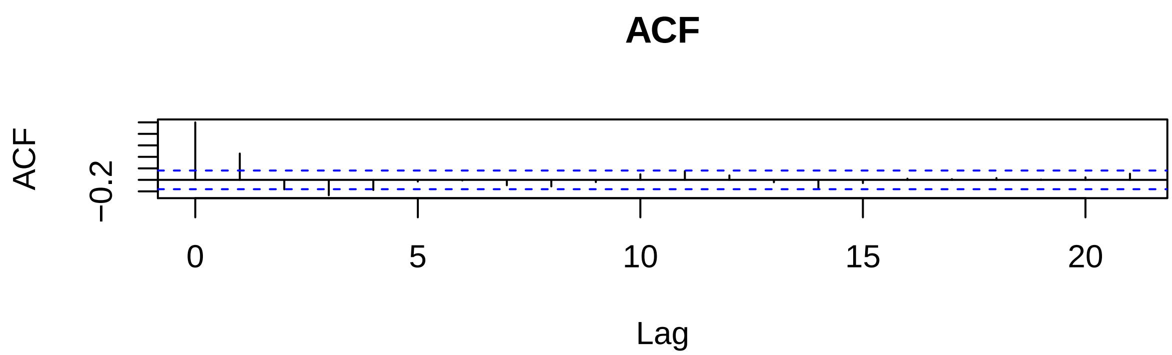

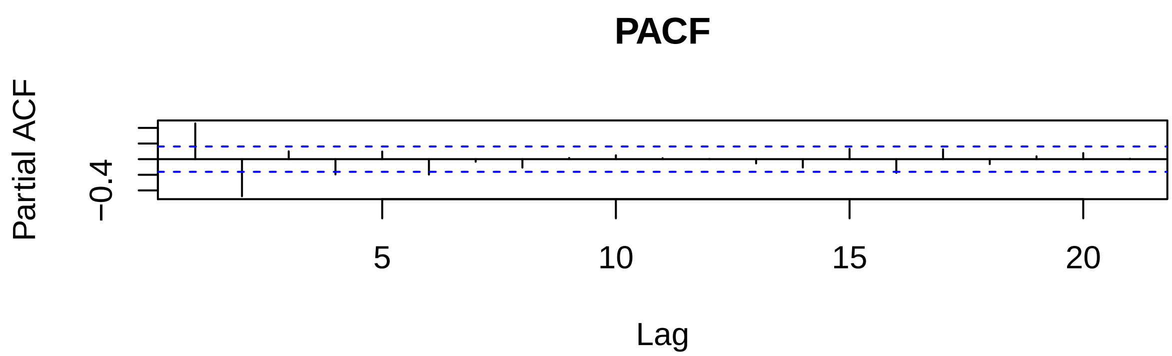

Vemos que a ACF decresce de forma mais gradual, enquanto a PACF possui valores significativos para o lag 1 e 2, e depois se tornam valores pequenos, o que traz o indicativo de ser um modelo AR(2).

Vamos tentar fitar um modelo AR(2).

```
model1 <- arma(X[[1]], order = c(2, 0))
summary(model1)
```

```
##
## Call:
## arma(x = X[[1]], order = c(2, 0))
##
## Model:
## ARMA(2,0)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.3168 -0.7743  0.1256  0.6870  2.4984
##
## Coefficient(s):
##            Estimate  Std. Error  t value Pr(>|t|)
## ar1         0.68921     0.07292    9.451  < 2e-16 ***
## ar2        -0.48531     0.07289   -6.658 2.77e-11 ***
## intercept  -0.02129     0.08702   -0.245    0.807
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Fit:
## sigma^2 estimated as 1.113,  Conditional Sum-of-Squares = 159.18,  AIC = 435.98
```

Vamos visualizar inicialmente o modelo real e o previsto, e em sequência, o plot de resíduos.

```
plot(X[[1]], main = "Model for Series 1", ylab = "Z_t")
lines(model1$fitted.values, col = "red")
```

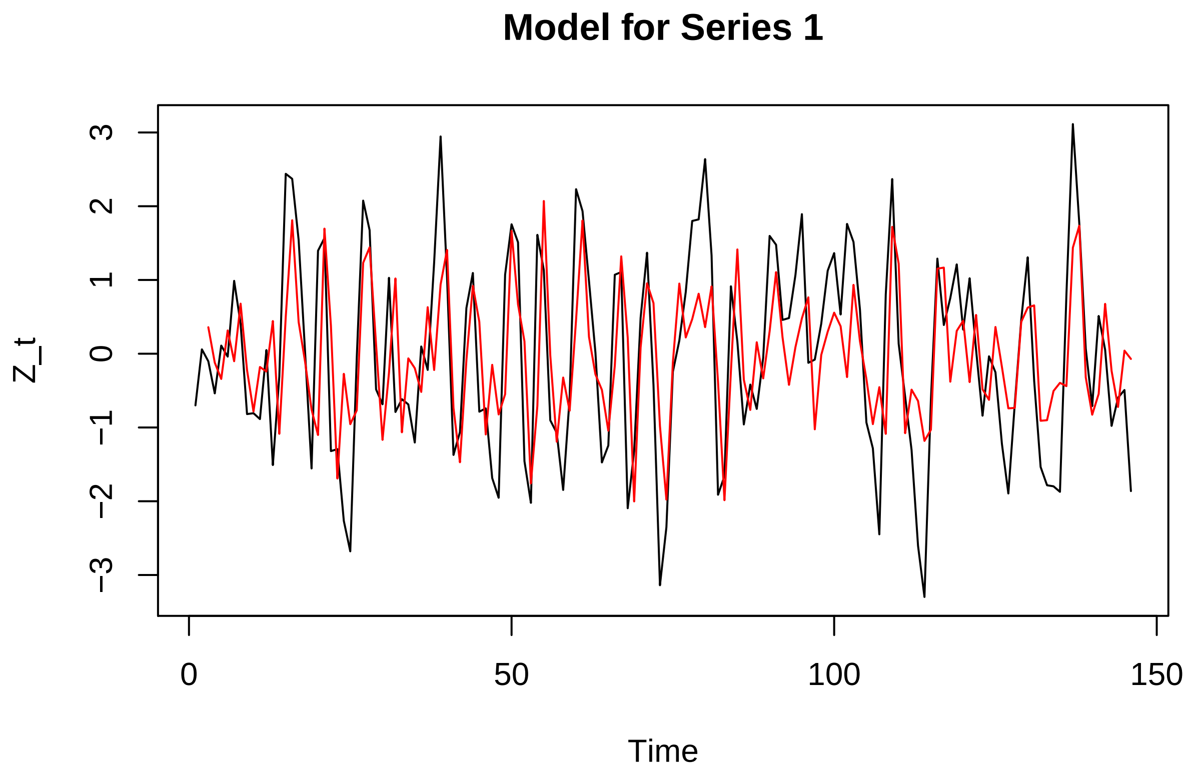


```
plot_res(model1$residuals)
```

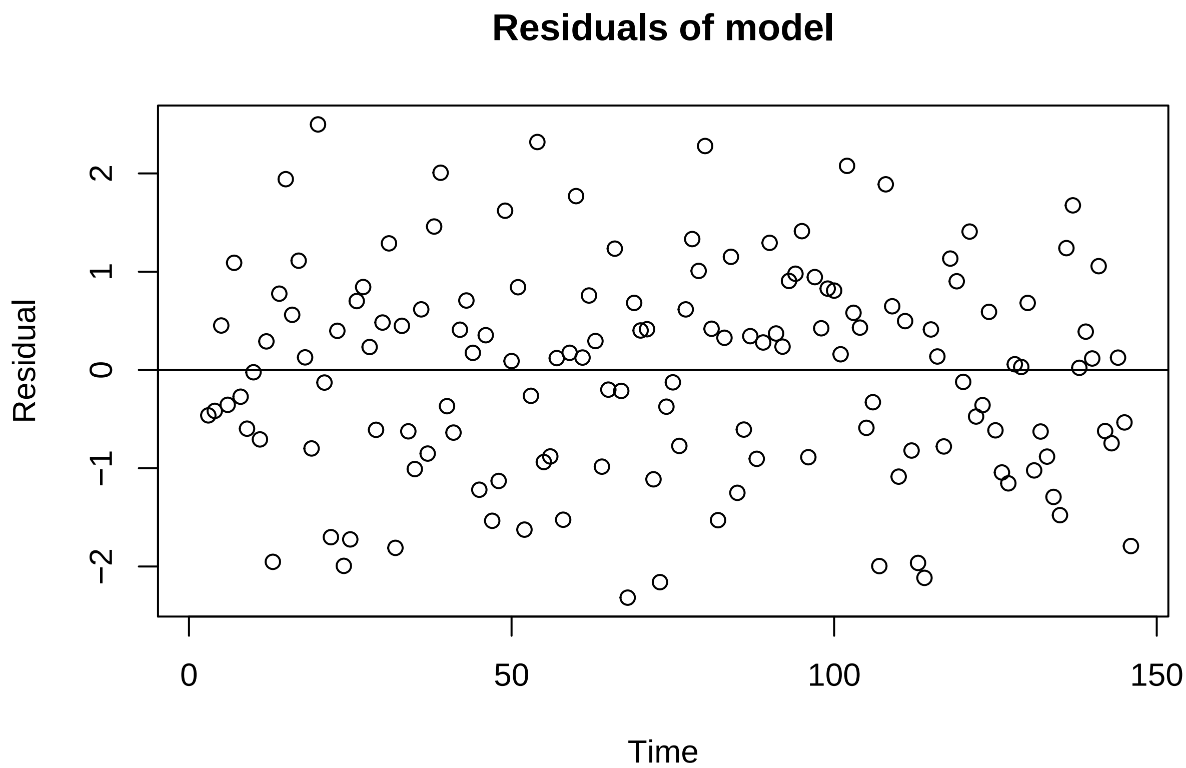

O modelo parece se adequar bem aos dados e também os resíduos não apresentam um padrão de comportamento.

Série 2

```
plot(X[[2]], main = "Series 2", ylab = "Z_t")
```

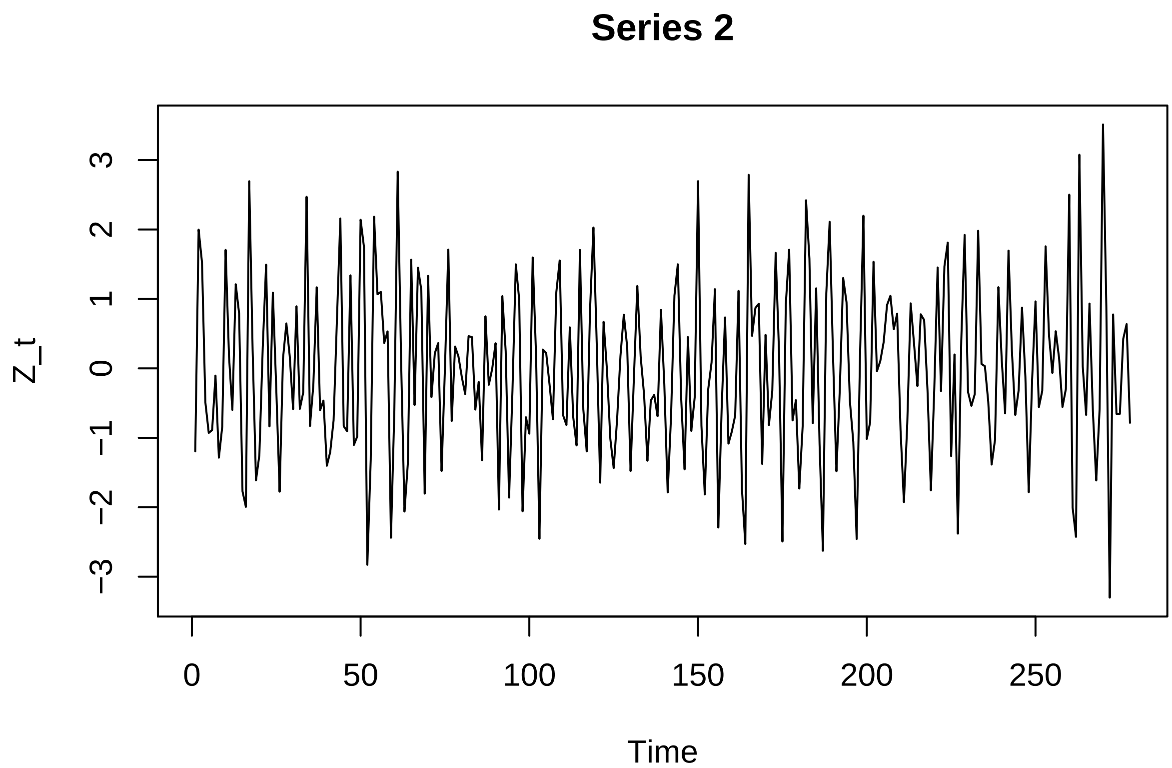


```
plot_acf_pacf(X[[2]])
```

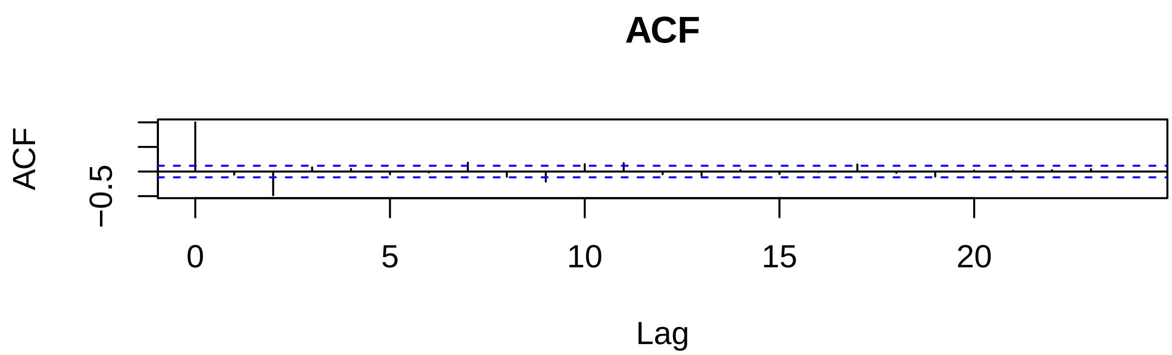

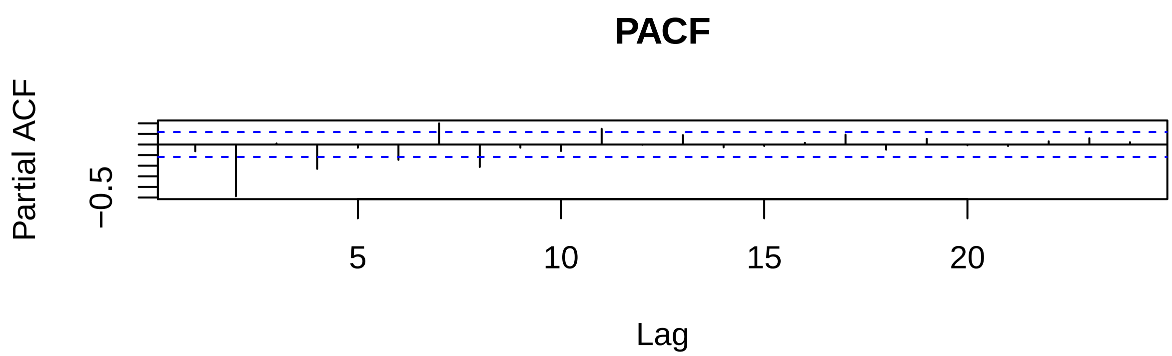

Agora, visualizamos um situação inversa, o lag 2 é significativo na ACF e nos demais não, e na PACF o decrescimento é gradual, o que nos faz pensar se tratar de um modelo MA(2).

```
model2 <- arma(X[[2]], order = c(0, 2))
summary(model2)
```

```
##
## Call:
## arma(x = X[[2]], order = c(0, 2))
##
## Model:
## ARMA(0,2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.49044 -0.77251  0.01282  0.77130  2.82319
##
## Coefficient(s):
##            Estimate  Std. Error  t value Pr(>|t|)
## ma1         0.11057     0.04029    2.745  0.00606 **
## ma2        -0.70037     0.03931  -17.818  < 2e-16 ***
## intercept  -0.03815     0.02510   -1.520  0.12855
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Fit:
```

```
## sigma^2 estimated as 1.025,  Conditional Sum-of-Squares = 281.95,  AIC = 801.86
```

O modelo se encaixou bem, vamos comparar a previsão e o real, e em sequência, o plot de resíduos.

```r
plot(X[[2]], main = "Model for Series 2", ylab = "Z_t")
lines(model2$fitted.values, col = "red")
```

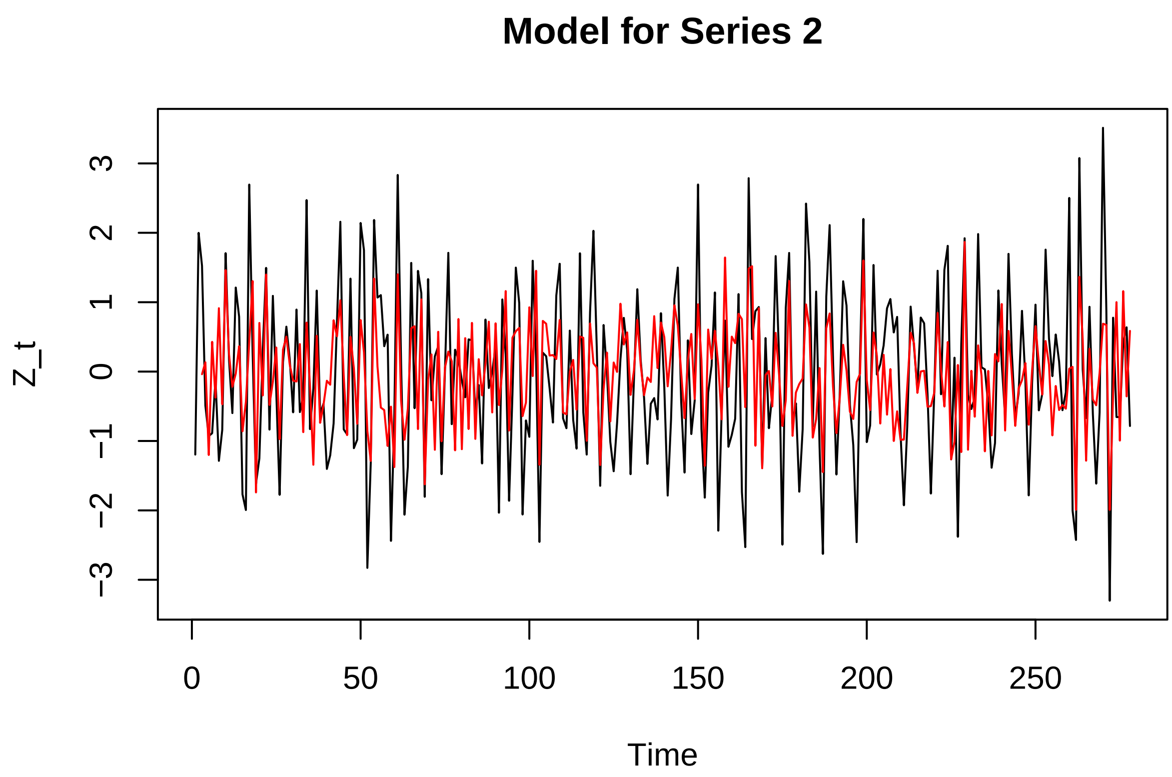


```r
plot_res(model2$residuals)
```

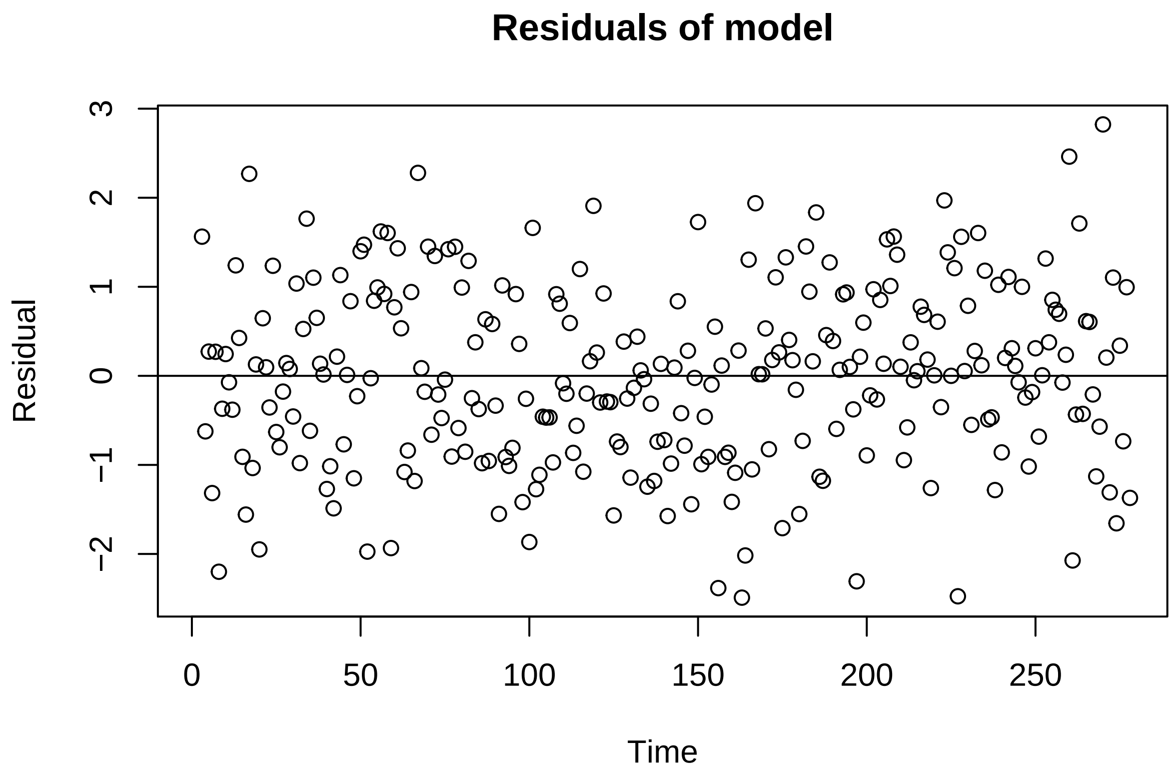

O modelo aparentemente se adequa bem a sazonalidade da série real, no entanto, não conseguimos capturar os picos extremos como ocorrem na série real, e os resíduos também se distribuem uniformemente ao longo da série.

Série 3

```
plot(X[[3]], main = "Series 3", ylab = "Z_t")
```

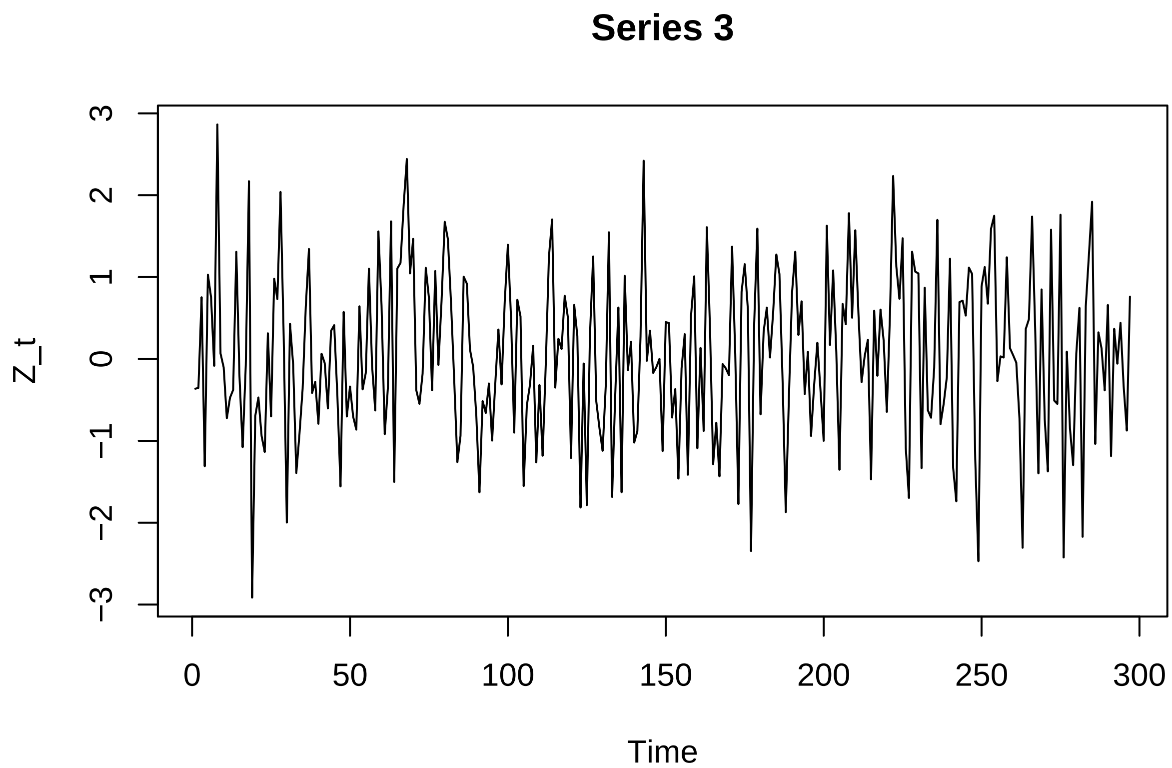


```
plot_acf_pacf(X[[3]])
```

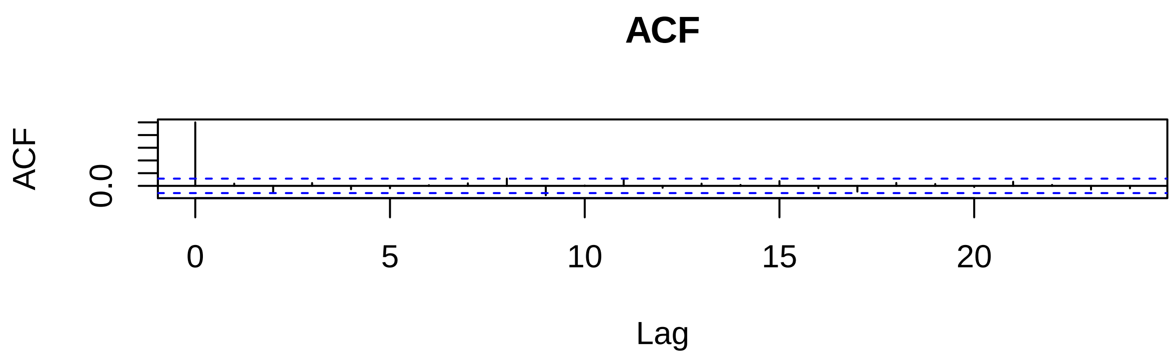

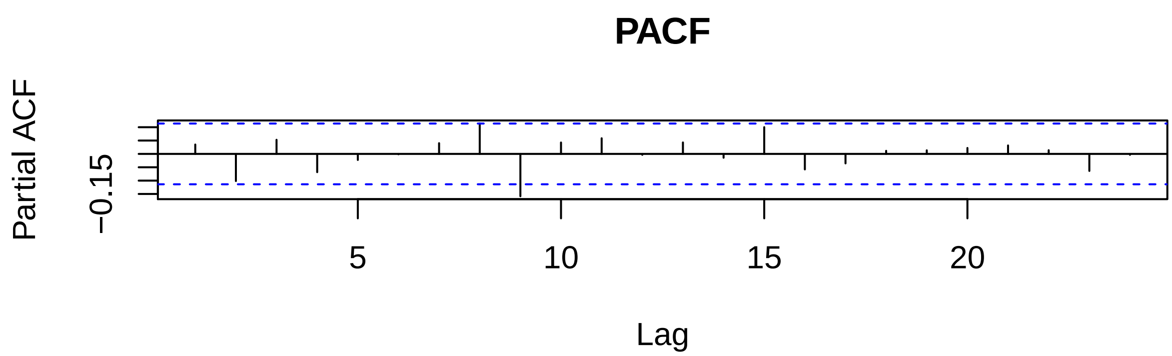

Nesse modelo existe um comportamento diferente dos demais, tanto a ACF quanto a PACF são praticamente nulas para todos os valores, menos para a ACF de 0, o que indica que as amostras não possuem covariância, se comportando como um ruído branco. Vamos verificar a média e a variância da série.

```
data.frame(mean = mean(X[[3]]), variance = var(X[[3]])*296/297)
```

```
##          mean variance
## 1 0.03941307 1.021629
```

Vemos que o modelo se comporta como um ruído branco, isto é, a_t com $E(a_t) = 0$ e $Var(a_t) = 1$. Se nós gerarmos 297 amostras de a_t e visualizarmos tanto o modelo e predição, quanto o residual, teremos:

```
model3 <- rnorm(297)
plot(X[[3]], main = "Model for Series 3", ylab = "Z_t")
lines(model3, col = "red")
```

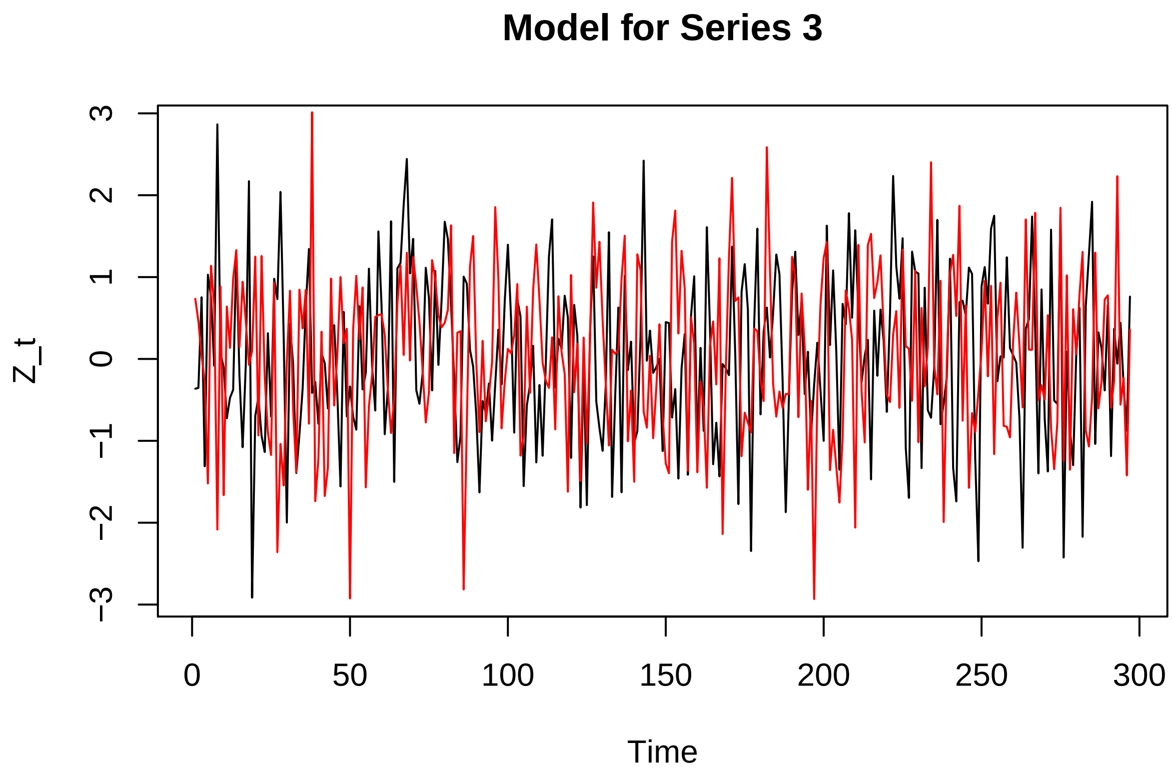


```
model3$residual <- X[[3]] - model3
```

```
## Warning in model3$residual <- X[[3]] - model3: Realizando coerção de LHD para
## uma lista
```

```
plot_res(model3$residual)
```

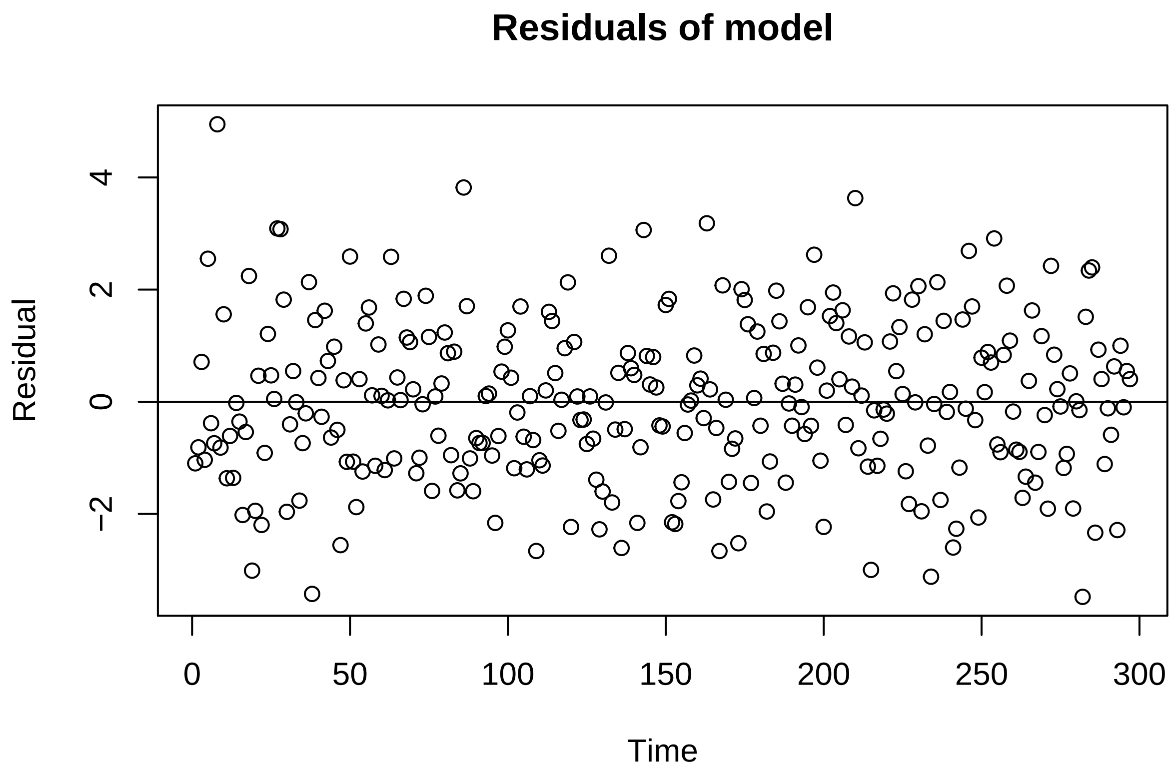

Série 4

```
plot(X[[4]], main = "Series 4", ylab = "Z_t")
```

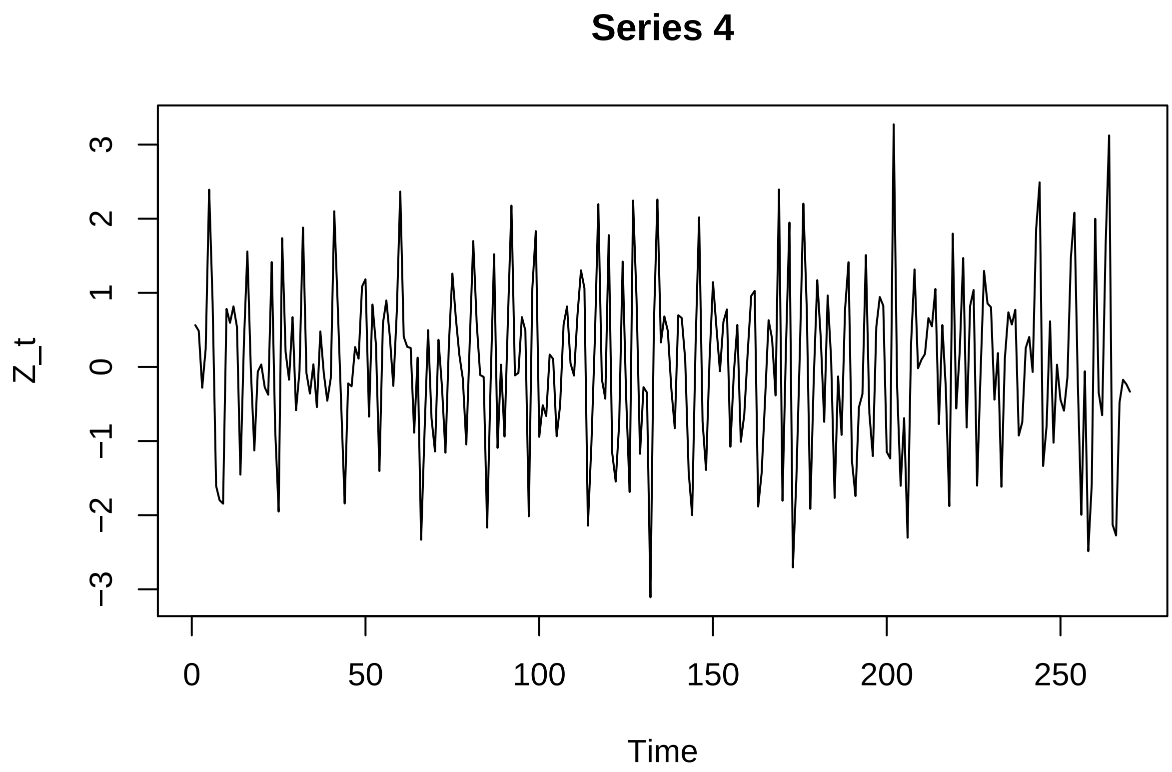


```
plot_acf_pacf(X[[4]])
```

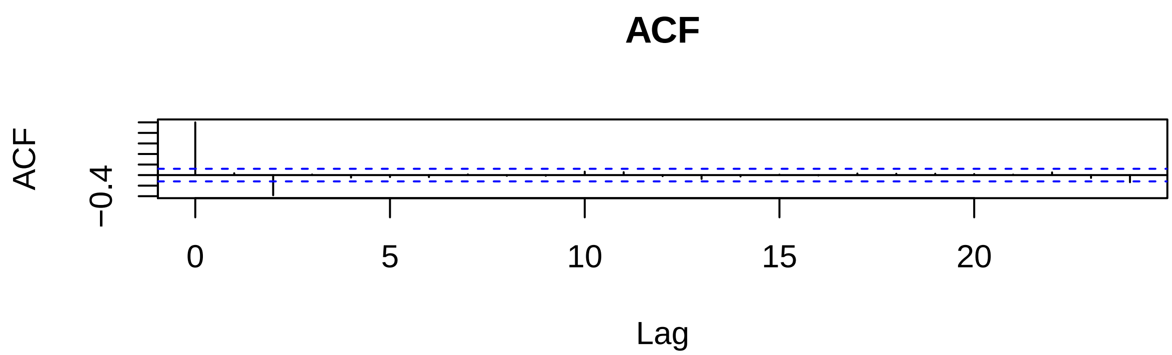

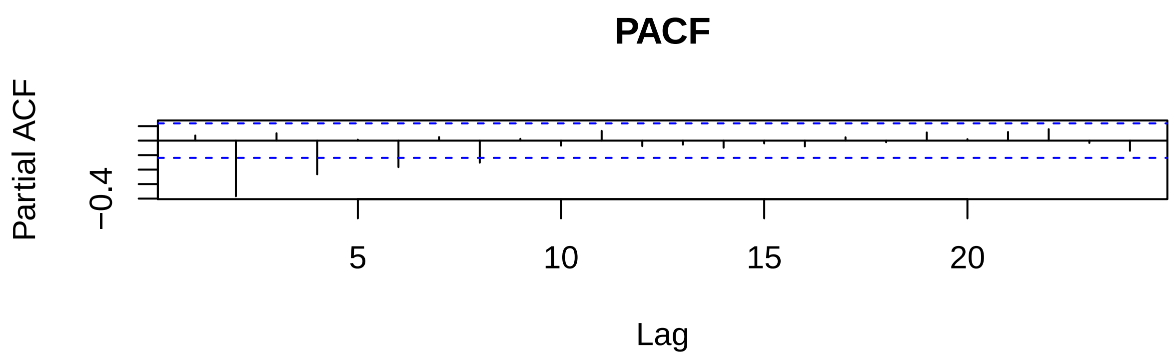

A série apresenta uma função de ACF que cai drasticamente após o lag 2, enquanto a PACF cai mais gradualmente, o que dá a noção de se tratar de um modelo MA(2). Utilizando dessa observação, fitamos:

```
model4 <- arma(X[[4]], order = c(0, 2))
summary(model4)
```

```
##
## Call:
## arma(x = X[[4]], order = c(0, 2))
##
## Model:
## ARMA(0,2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.20748 -0.68404  0.06891  0.64994  2.84235
##
## Coefficient(s):
##            Estimate  Std. Error  t value Pr(>|t|)
## ma1         0.09013     0.05112    1.763   0.0779 .
## ma2        -0.61589     0.05318  -11.581   <2e-16 ***
## intercept   0.01590     0.02884    0.551   0.5813
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Fit:
```

```
## sigma^2 estimated as 0.9865,  Conditional Sum-of-Squares = 263.41,  AIC = 768.57
```

```r
plot(X[[4]], main = "Model for Series 4", ylab = "Z_t")
lines(model4$fitted.values, col = "red")
```

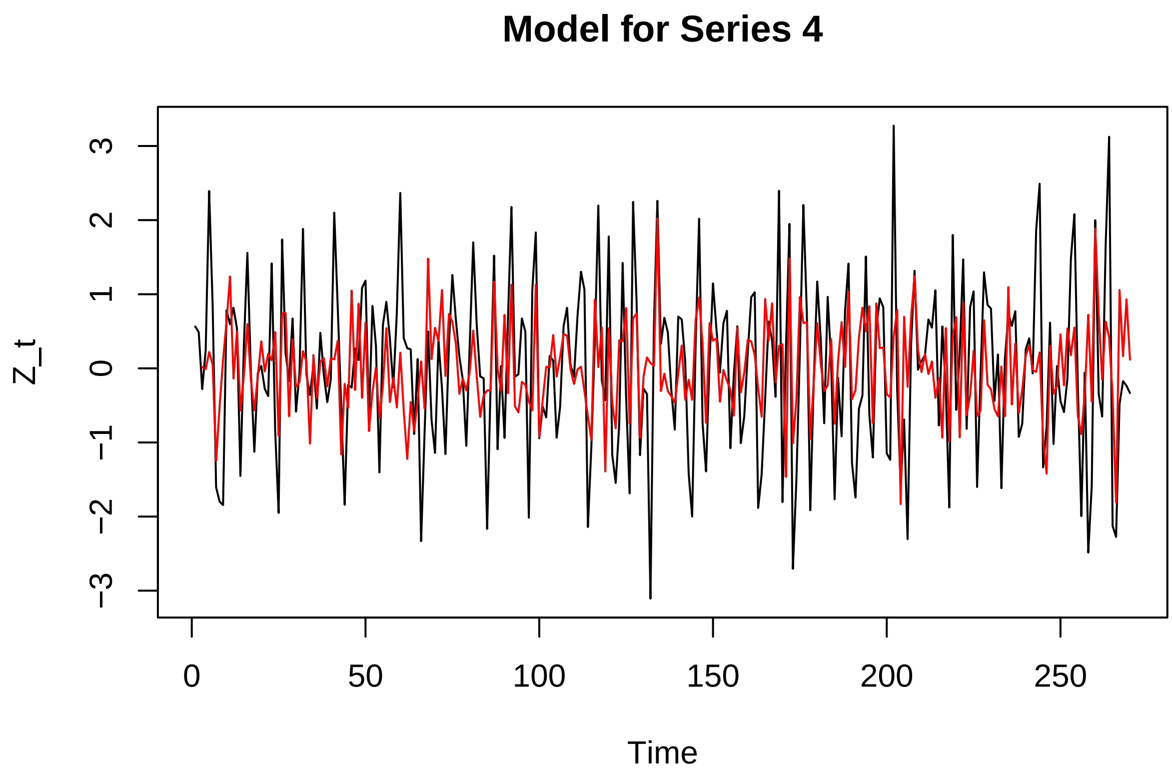


```r
plot_res(model4$residuals)
```

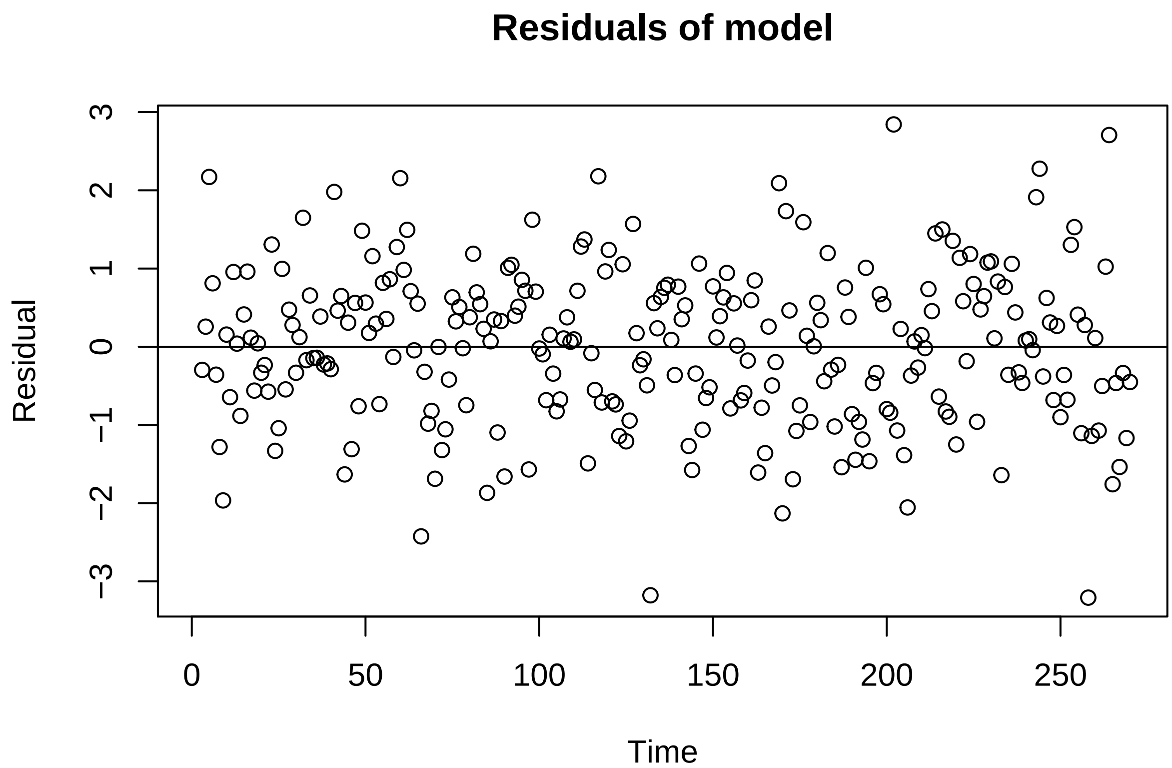

O modelo se encaixou bem aos dados, incluindo apresentando uma distribuição uniforme dos ruídos.

Série 5

```
plot(X[[5]], main = "Series 5", ylab = "Z_t")
```

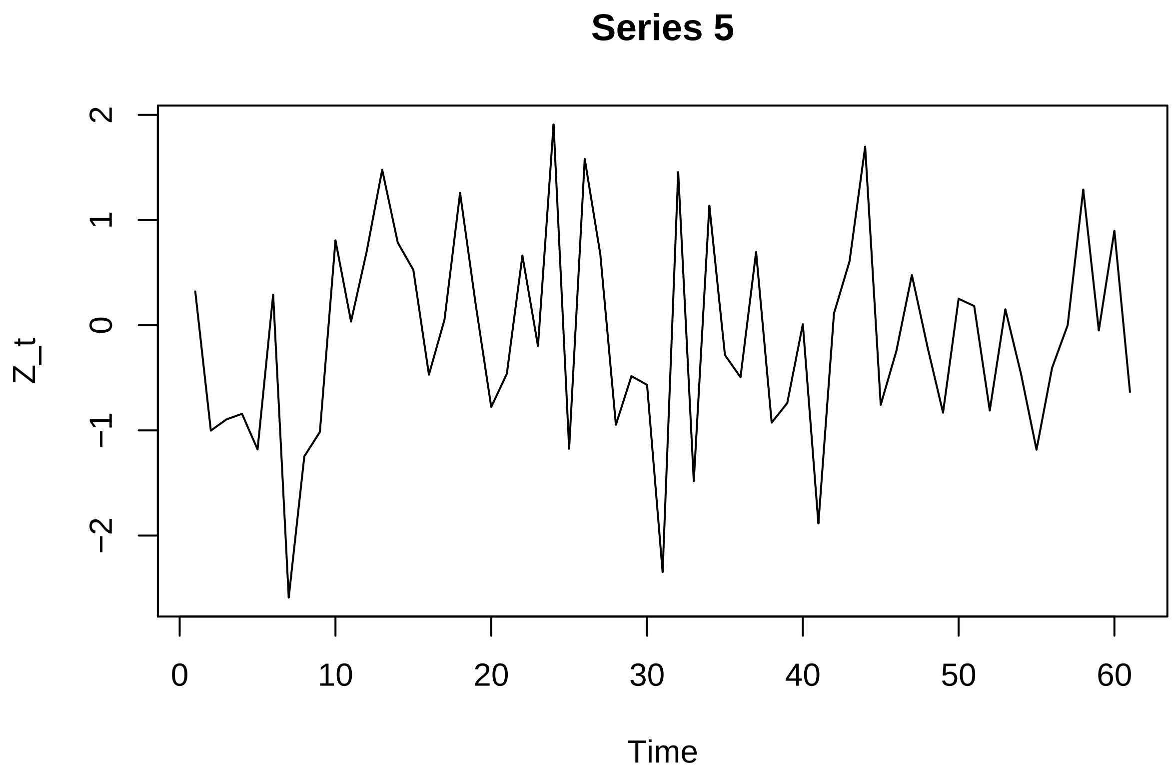


```
plot_acf_pacf(X[[5]])
```

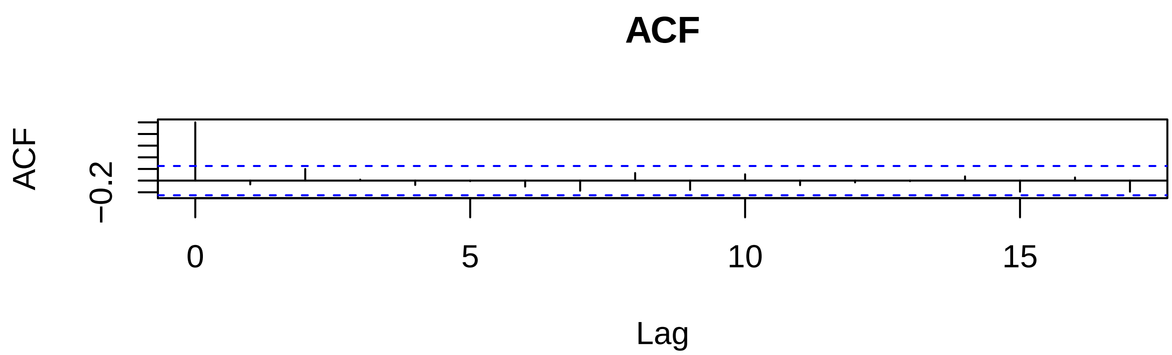

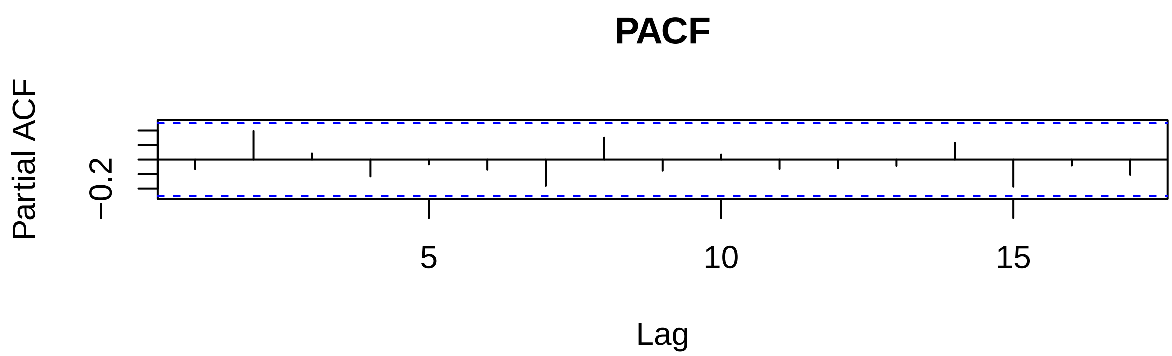

Vemos que tanto a ACF quanto a PACF são extremamente baixas para valores diferentes de 0, no entanto, nessa série possuímos bem menos amostras que as demais, possuindo apenas 61 amostras. Por esse motivo, iremos considerar que a importância do segundo lag na PACF e avaliar dois modelos distintos, AR(2) e ARMA(2, 2). Considerando primeiro o modelo AR(2).

```
model5 <- arma(X[[5]], order = c(2, 0))
summary(model5)
```

```
##
## Call:
## arma(x = X[[5]], order = c(2, 0))
##
## Model:
## ARMA(2,0)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.24498 -0.70396  0.01893  0.71961  1.85873
##
## Coefficient(s):
##            Estimate  Std. Error  t value Pr(>|t|)
## ar1        -0.04726     0.12481   -0.379    0.705
## ar2         0.20225     0.12576    1.608    0.108
## intercept  -0.09259     0.12355   -0.749    0.454
##
## Fit:
```

```
## sigma^2 estimated as 0.9154,  Conditional Sum-of-Squares = 53.09,  AIC = 173.72
```

```r
plot(X[[5]], main = "Model for Series 5 AR(2)", ylab = "Z_t")
lines(model5$fitted.values, col = "red")
```

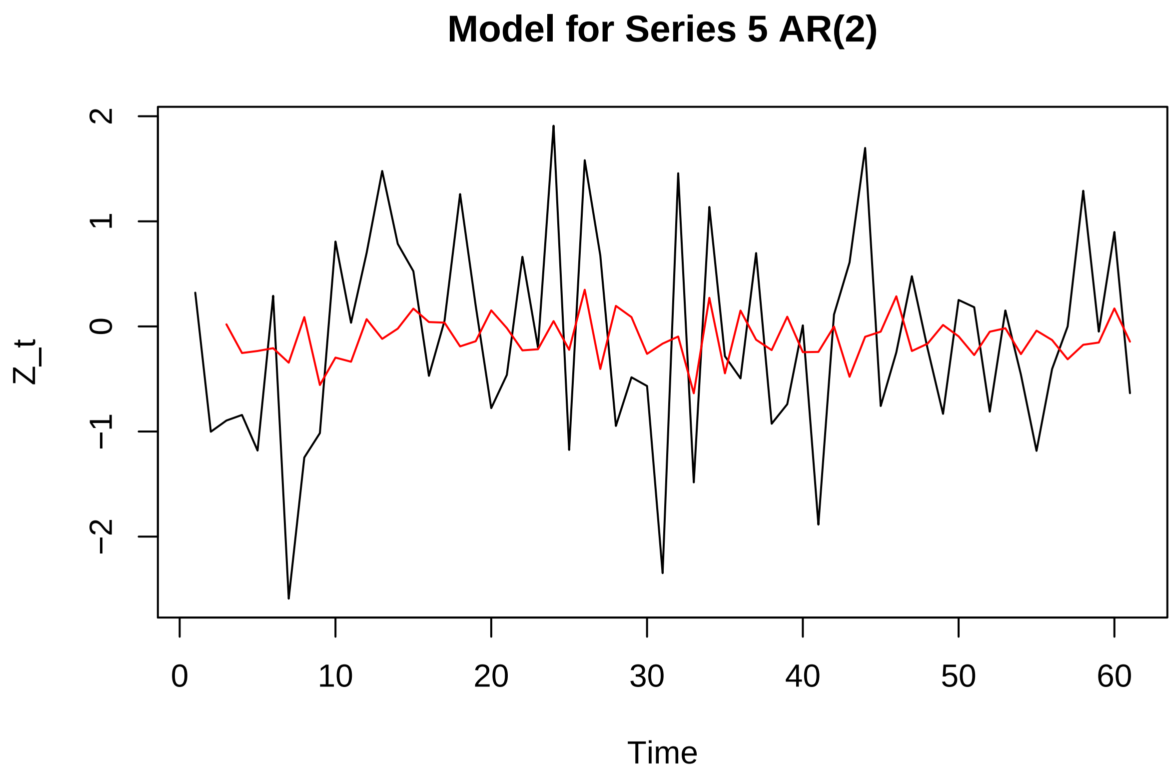

E agora o modelo ARMA(2, 2).

```r
model5 <- arma(X[[5]], order = c(2, 2))
summary(model5)
```

```
##
## Call:
## arma(x = X[[5]], order = c(2, 2))
##
## Model:
## ARMA(2,2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.16208 -0.48610 -0.01902  0.57863  2.30147
##
## Coefficient(s):
##            Estimate  Std. Error  t value Pr(>|t|)
## ar1         0.81736     0.17739    4.608 4.07e-06 ***
## ar2        -0.62001     0.10722   -5.783 7.35e-09 ***
```

```
## ma1        -0.92912     0.09675   -9.603  < 2e-16 ***
## ma2         0.95619     0.10319    9.266  < 2e-16 ***
## intercept  -0.12685     0.11679   -1.086    0.277
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Fit:
## sigma^2 estimated as 0.8179,  Conditional Sum-of-Squares = 47.54,  AIC = 170.85
```

```r
plot(X[[5]], main = "Model for Series 5 ARMA(2, 2)", ylab = "Z_t")
lines(model5$fitted.values, col = "red")
```

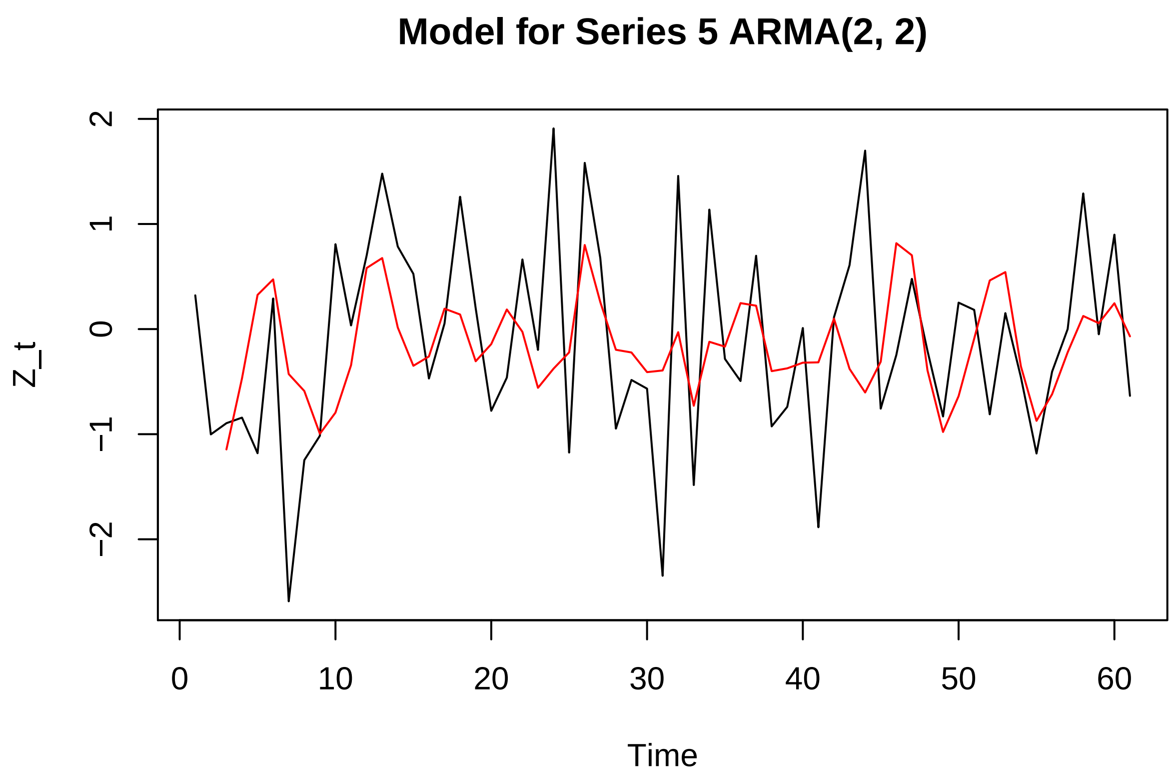

Vemos que o modelo ARMA(2, 2) apresentou um AIC menor, de 170, em comparação com o AR(2), além disso, ele também encaixou melhor na curva real dos dados. Vamos visualizar os resíduos:

```r
plot_res(model5$residuals)
```

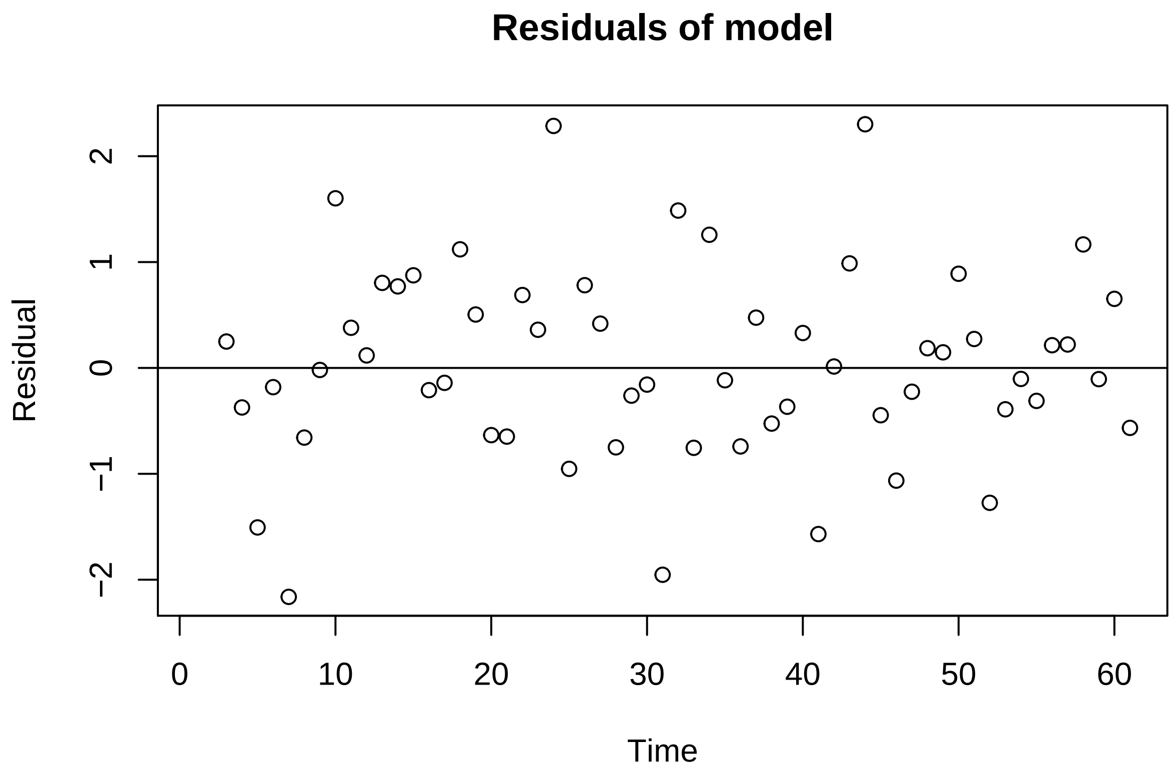
Residuals of model
Residual
Time
2
1
0
−1
−2
0
10
20
30
40
50
60