

Análise de intervenção


Giovani Valdrighi, Vitória Guardieiro

11/12/2020

Total Business Sales FRED

- ▶ Dados de 01/2002 até 12/2012, com intervenção em 07/2008. O período de 01/2013 para 12/2014 será usado como validação do modelo.
- ▶ Em 2008 ocorreu uma crise bancária internacional, fortemente afetando as vendas no EUA.


Total Business Sales FRED (FED St. Louis Economics Research)



- ▶ Etapas da modelagem:
 - ▶ Estabilização da variância
 - ▶ 1º: modelo SARIMA pré-intervenção
 - ▶ Diferenciação para remoção de tendência
 - ▶ Identificação do modelo com ACF e PACF
 - ▶ Escolha de modelo
 - ▶ 2º: Modelagem de intervenção
 - ▶ Detecção de intervenção
 - ▶ Avaliação de funções de transferência

Estabilização da variância


- ▶ Com a transformação de BoxCox o lambda é 0.137.



SARIMA pré-intervenção





- Modelo com dados até 07/2008. Os plots e modelagem utilizam os dados transformados.

Total Business Sales FRED (FED St. Louis Economics Research)



Diferenças





- Vamos identificar os parâmetros d e D do modelo SARIMA.



- ▶ Uso do teste Augmented Dickey Fuller para verificar se existe tendência.
- ▶ ADF test p-valores:
 - ▶ Série original: 0.01
 - ▶ Diff() series: 0.0206
 - ▶ Diff() Diff() series: 0.01
 - ▶ Diff() Diff(12) series: 0.01
- ▶ Nós vamos usar $d = 1$ e $D = 0$ ou $D = 1$.

ACF e PACF

- Plotar a ACF e PACF do modelo para identificar os parâmetros p, q, P, Q .



- ▶ Tanto nos plots não-sazonais e sazonais a ACF decresce lentamente, indicando um modelo auto regressivo.
- ▶ Para as PACFs não-sazonais, nós temos os primeiros dois lags significantes e para a sazonal nós temos os três primeiros lags significantes.
- ▶ Vamos avaliar os seguintes modelos:
 - ▶ SARIMA(2, 1, 1)(3, 0, 1)
 - ▶ SARIMA(2, 1, 1)(2, 0, 1)
 - ▶ SARIMA(2, 1, 1)(2, 1, 1)




SARIMA(2, 1, 1)(3,0,1)

```
## Series: FRED_pre
## ARIMA(2,1,1)(3,0,1)[12]
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:

## Warning in sqrt(diag(x$var.coef)): NaNs produzidos

##          ar1      ar2      ma1      sar1      sar2      sar3      sma1
##      -1.0841  -0.6725  0.3762  -0.0028  0.6105  0.2732  0.8088
## s.e.   0.1669   0.0988  0.2214      NaN      NaN   0.1557      NaN
##
## sigma^2 estimated as 0.0193:  log likelihood=34.32
## AIC=-52.63   AICc=-50.57   BIC=-33.67
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 1886.588 20274.27 16172.38 0.1815222 1.621103 0.2541459
##              ACF1
## Training set -0.04002457
```




Residuals from ARIMA(2,1,1)(3,0,1)[12]



SARIMA(2, 1, 1)(2,0 ,1)

```
## Series: FRED_pre
## ARIMA(2,1,1)(2,0,1)[12]
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1
##      -1.0998  -0.6944  0.3887  1.3894  -0.3895  -0.9628
## s.e.   0.1522   0.1011  0.2013  0.1652   0.1651   0.1334
##
## sigma^2 estimated as 0.01554:  log likelihood=36.49
## AIC=-58.99   AICc=-57.41   BIC=-42.4
##
## Training set error measures:
##              ME  RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 1927.329 18390 14675.48 0.182487 1.468923 0.2306223 -0.03922664
```




Residuals from ARIMA(2,1,1)(2,0,1)[12]




SARIMA(2, 1, 1)(2,1,1)

```
## Series: FRED_pre
## ARIMA(2,1,1)(2,1,1)[12]
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1
##      -1.0979  -0.7046  0.4394  0.3592  -0.2377  -0.9998
## s.e.   0.1599   0.0989  0.2389  0.1512   0.1785   0.4891
##
## sigma^2 estimated as 0.01376:  log likelihood=41.06
## AIC=-68.13   AICc=-66.23   BIC=-52.69
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 824.437 16261.08 11894.78 0.0635975 1.159562 0.1869242 -0.03438936
```

Residuals from ARIMA(2,1,1)(2,1,1)[12]




- O modelo com menor AIC é o SARIMA(2, 1, 1)(2, 1, 1).



Predição pré-intervenção

- Nós agora olhamos para como o nosso modelo diz que a série deveria se comportar caso não houvesse a intervenção em julho de 2008.

FRED series x Forecast of pre-intervention model SARIMA(2, 1,1)(2,1,1)



Modelagem de intervenção

- ▶ Vamos considerar diferentes modelagens de intervenção, variando a função de transferência.

Efeito permanente constante

- ▶ Para o primeiro modelo de intervenção, nós vamos definir $h_t = I(t > \text{jul}/2008)\delta_0$, então vamos ter um efeito permanente igual a δ_0 quando o tempo for maior do que julho de 2008.
- ▶ O valor δ_0 estimado é 0.1105 com s.e. 0.1492, então o intervalo inclui 0.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      xreg
##          0.4543  0.2465 -0.5897  0.2995 -0.3439 -1.0  0.1105
## s.e.  0.1585  0.0904   0.1395  0.0969   0.0946   0.1  0.1492
##
## sigma^2 estimated as 0.0263:  log likelihood=35.34
## AIC=-54.69  AICc=-53.38  BIC=-32.46
##
## Training set error measures:
##              ME  RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -845.9794 24414 17468.18 -0.09032853 1.629346 0.2050465 -0.0618996
```

Efeito temporário constante


- ▶ Agora para o modelo de intervenção nós vamos definir $h_t = I(t = \text{jul}/2008)\delta_0$, então haverá um efeito temporário de valor δ_0 em julho de 2008.
- ▶ O valor δ_0 estimado é 0.2209 com s.e. 0.1134, então o intervalo não inclui 0.
- ▶ O AIC também foi menor do que o modelo de efeito permanente.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      xreg
##      0.4749  0.2230 -0.6151  0.2804 -0.3408 -1.0000  0.2209
## s.e.  0.1695  0.0918   0.1521  0.0989   0.0955   0.0992  0.1134
##
## sigma^2 estimated as 0.02554:  log likelihood=37
## AIC=-58   AICc=-56.69   BIC=-35.77
##
## Training set error measures:
##              ME  RMSE      MAE      MPE      MAPE      MASE
## Training set -805.7189 23866 17205.32 -0.08929967 1.609214 0.2019609
##              ACF1
## Training set -0.05589136
```

Identificação de outliers

- ▶ São indentificados dois pontos de mudança, em agosto de 2008 e novembro de 2008, usaremos esse resultados em um modelo posterior.

```
## Warning in locate.outliers.iloop(resid = resid, pars = p
## stopped when 'maxit.iloop' was reached
```




Efeito de intervenção decrescente


- ▶ Agora nós modelamos a função de transferência como um $AR(1)$, isso é, $h_t = \frac{I(t=jul/2008)\delta_0}{1-\omega_0 B}$ nós podemos ter um efeito mais complexo, sem ser uma mudança cosntante na média.
- ▶ Com os valores estimado para δ_0 e ω_0 nós podemos calcular a curva de transferência.

```
##
## Call:
## arimax(x = BoxCox(FRED, lambda), order = c(2, 1, 1), seasonal = list(order = c(2,
##      1, 1), frequency = 12), include.mean = FALSE, method = "CSS", xtransf = temporary_const_eff,
##      transfer = list(c(1, 0)))
##
## Coefficients:
##      ar1      ar2      ma1      sar1      sar2      sma1  T1-AR1  T1-MA0
##      0.6262  0.1537 -0.5044  0.1578 -0.5649 -0.8734 -0.2868  0.2074
## s.e.  0.3524  0.0957  0.2007  0.0557  0.1168  0.0582  0.2576  0.0922
##
## sigma^2 estimated as 0.03239:  part log likelihood = 35.23
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.001950638 0.1510535 0.09214914 -0.004856425 0.2199494 0.2738843
##              ACF1
## Training set -0.03711821
```


FRED Real x Predicted with decreasing effect




AR(1) effect




- A curva mostra um crescimento e depois um decrescimento, enquanto nós esperaríamos um decrescimento. Além disso, com o resultado do TSA, nós podemos considerar que a intervenção realizada em julho só exhibe resultados em agosto, ou seja podemos tentar modelar usando $I(t = \text{aug}2008)$.

```
##
## Call:
## arimax(x = BoxCox(FRED, lambda), order = c(2, 1, 1), seasonal = list(order = c(2,
## 1, 1), frequency = 12), include.mean = FALSE, method = "CSS", xtransf = 1 *
## (seq_along(fred_FIT$DATE) == 80), transfer = list(c(1, 0)))
##
## Coefficients:
##      ar1      ar2      ma1      sar1      sar2      sma1      T1-AR1      T1-MA0
##      0.5626  0.1683 -0.4415  0.1721 -0.5738 -0.8657 -0.1767 -0.1517
## s.e.  0.3305  0.0957  0.1999  0.0554  0.1173  0.0588  0.2539  0.0939
##
## sigma^2 estimated as 0.03326:  part log likelihood = 33.65
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.001567093 0.1530746 0.09464437 -0.003913121 0.2258248 0.2813006
##              ACF1
## Training set -0.03549577
```

FRED Real x Predicted with decreasing effect



AR(1) effect



- ▶ Com a curva de transferência computada, nós podemos usar isso como um regressor em um modelo ARIMA. Nesse primeiro modelo vamos usar a intervenção em julho.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      xreg
##          0.4749  0.2230 -0.6151  0.2804  -0.3408  -1.0000  1.0653
## s.e.    0.1695  0.0918   0.1521  0.0989   0.0955   0.0992  0.5469
##
## sigma^2 estimated as 0.02554:  log likelihood=37
## AIC=-58   AICc=-56.69   BIC=-35.77
##
## Training set error measures:
##              ME  RMSE      MAE      MPE      MAPE      MASE
## Training set -805.7189 23866 17205.32 -0.08929967 1.609214 0.2019609
##              ACF1
## Training set -0.05589136
```

► Agora com a intervenção em agosto.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      xreg
##          0.4463  0.2253 -0.5600  0.3113  -0.3528  -1.0000  0.9449
## s.e.      0.1740  0.0916   0.1596  0.0970   0.0951   0.1007  0.6762
##
## sigma^2 estimated as 0.02598:  log likelihood=36.01
## AIC=-56.02   AICc=-54.71   BIC=-33.78
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -797.8675 24168.06 17634.64 -0.08787438 1.646041 0.2070005
##              ACF1
## Training set -0.04194703
```

- ▶ Até então, o modelo com intervenção que apresentou menor AIC foi o com intervenção temporária em julho de 2008 e com intervenção decrescente começando em julho de 2008.
- ▶ Vamos utilizar dos resultados da detecção de outliers para construir um modelo de intervenção.

Duas intervenções permanentes

- ▶ Modelo com intervenção permanente em agosto e em novembro de 2008.
- ▶ Modelo obteve menor AIC até o momento, apresentando um resultado muito melhor que os demais.
- ▶ Os parâmetros de intervenção possuem intervalo longe do 0.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      LS80      LS83
##      -1.0130  -0.5927  0.5961  0.2221  -0.3036  -1.000  -0.4940  -0.9680
## s.e.   0.1376   0.0765  0.1827  0.0952   0.1021   0.118   0.1017   0.1082
##
## sigma^2 estimated as 0.01434:  log likelihood=71.95
## AIC=-125.89  AICc=-124.24  BIC=-100.88
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 363.7584 17702.75 13198.04 0.01605244 1.244261 0.1549223
##              ACF1
## Training set 0.001711118
```

Intervenção de 3 meses


- ▶ Com o resultado do TSA também podemos considerar uma intervenção constante temporária que dure 3 meses.
- ▶ AIC foi menor do que modelo com duas intervenções permanentes.

```
## Series: FRED
## Regression with ARIMA(2,1,1)(2,1,1)[12] errors
## Box Cox transformation: lambda= 0.1370143
##
## Coefficients:
##          ar1      ar2      ma1      sar1      sar2      sma1      xreg
##          0.4611  0.2086 -0.5515  0.3115 -0.3680 -1.0000 -0.1454
## s.e.    0.1784  0.0965   0.1640  0.0968   0.0955   0.1007   0.1103
##
## sigma^2 estimated as 0.02589:  log likelihood=35.94
## AIC=-55.88   AICc=-54.57   BIC=-33.65
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -783.5794 24074.92 17565.27 -0.0888909 1.640885 0.2061862
##              ACF1
## Training set -0.04780914
```



Predição modelo de intervenção decrescente

- Predição de 12 meses e 24 meses para o modelo com intervenção em julho de 2008 e com transferência decrescente.

FRED series x Forecast of one decrescent intervention model 12 months




FRED series x Forecast of of one decrescent intervention model 24 months



Predição com modelo de duas intervenções permanentes

FRED series x Forecast of two permanent interventions model 12 months



FRED series x Forecast of two permanent interventions model 24 months

